

Прогнозирование отмены бронирований отеля

Проект по курсу «Технологии искусственного интеллекта и продвинутой аналитики»

Автор: Доровских Софья Дмитриевна, Соловьева Амина, МБАВК251С

1. Введение

Бизнес-задача. Отель теряет выручку, когда гости отменяют брони в последний момент: номер остаётся пустым, и перепродать его уже поздно. Если заранее выявлять брони с высоким риском отмены, отель может эффективнее управлять овербукингом, депозитами и условиями отмены.

Данные. Использован публичный набор Hotel Booking Demand с Kaggle — 119 390 бронирований городского и курортного отелей (Португалия, 2015–2017) с 32 признаками. Целевая переменная — `is_canceled` (1 — бронь отменена, 0 — гость заехал).

Цель проекта. Построить и обосновать модель бинарной классификации, предсказывающую отмену брони, сравнить несколько алгоритмов и интерпретировать факторы отмены. Целевая метрика — F1-score: классы несбалансированы (отмен ~37%), поэтому Accuracy обманчива (тривиальный прогноз «не отменится» даёт 63%), а F1 балансирует precision и recall.

2. Анализ данных (EDA)

Целевая переменная распределена как 37% отмен против 63% заездов — умеренный дисбаланс. Среди числовых признаков сильнее всего с отменой связан срок до заезда (`lead_time`, положительно), а число спецзапросов и заказ парковки — отрицательно; при этом все линейные корреляции слабые ($|r| < 0,3$), что указывает на нелинейный характер зависимостей.

Ключевые закономерности: брони с типом депозита Non Refund отменяются почти в 100% случаев; городской отель отменяют чаще курортного (~42% против ~28%); чем больше срок до заезда, тем выше доля отмен.




Рис. 1. Доля отмен в зависимости от типа депозита и типа отеля.

3. Подготовка данных (Feature Engineering)

Удалены строки-аномалии (брони без гостей; отрицательная и экстремальная цена adr) и колонки-утечки reservation_status и reservation_status_date, напрямую раскрывающие исход брони. Колонка company (~94% пропусков) удалена; из колонки agent создан бинарный флаг agent_known.

Действие	Метод	Обоснование
Пропуски	числовые — медиана; категориальные — Unknown	медиана устойчива к выбросам; Unknown сохраняет строки
Кодирование	One-Hot; редкие страны → общий бакет	у country 177 значений — иначе сотни колонок
Масштабирование	StandardScaler (числовые)	нужно логрегу; деревьям не мешает
Новые признаки	флаг agent_known; удаление утечек	ID агента бесполезен как число; статус раскрывает ответ

Выборка разделена на train (80%) и test (20%) со стратификацией (доля отмен 0,371 в обеих частях). Подбор моделей — на 5-fold кросс-валидации внутри train. Все преобразования собраны в единый Pipeline и обучаются только на обучающих данных, что исключает утечку информации из теста.

4. Моделирование

Отправная точка — baseline (DummyClassifier, всегда «не отменится»): Accuracy 0,63 при F1 = 0. Затем обучены и сравнены четыре модели; качество оценивалось по F1 на кросс-валидации и на отложенном тесте.

Модель	F1 (тест)	Accuracy	Время
Baseline	0,00	0,63	—
Logistic Regression	0,72	0,81	5 с
Decision Tree	0,77	0,84	3 с
Gradient Boosting	0,81	0,86	9 с
Random Forest	0,85	0,89	31 с

Выбор модели. Лучший результат — Random Forest (F1 0,85, Accuracy 0,89). F1 на кросс-валидации (0,84) практически совпадает с тестом (0,85) — переобучения нет. Подбор гиперпараметров (RandomizedSearchCV) не дал заметного прироста: базовая конфигурация уже близка к оптимальной. Превосходство ансамблей над логистической регрессией подтверждает вывод EDA о нелинейности зависимостей. Если критична скорость, Gradient Boosting даёт близкое качество втрое быстрее.




Рис. 2. Важность признаков (Random Forest): срок до заезда, цена, страна, тип депозита.

Анализ ошибок. Для класса «отменено» precision составил 0,89, recall — 0,81. Главный тип ошибки — пропущенные отмены (модель предсказала «приедет», а гость отменил): именно они оборачиваются упущенной выручкой, поэтому при внедрении имеет смысл смещать порог в сторону повышения recall.




Рис. 3. Матрица ошибок финальной модели на тестовой выборке.

5. Инференс и воспроизводимость

Финальная модель сохранена целиком (предобработка + классификатор) в формате joblib (best_model.pkl, со сжатием). На новых «сырых» данных прогноз работает сразу — все трансформации применяются автоматически внутри pipeline. Воспроизводимость

обеспечена фиксированным `random_state`, загрузкой данных через `kagglehub` и фиксацией версий библиотек.

```
import joblib
model = joblib.load('best_model.pkl')
pred = model.predict(new_data)          # 0 / 1
proba = model.predict_proba(new_data)[:, 1] # вероятность отмены
```

6. Заключение

Что получилось. Построена и обоснована модель, предсказывающая отмену брони с F1 0,85 и Ассигасу 0,89. Ключевые факторы риска (срок до заезда, тип депозита, цена, страна, вовлечённость) понятны и интерпретируемы, что делает модель пригодной как скоринг риска брони.

Сложности. Обнаружение и устранение утечки данных, обработка высококардинального признака `country` (177 стран) и работа с дисбалансом классов при выборе метрики.

Уроки. Грамотная постановка задачи и метрики важнее погони за сложными моделями; чистый `baseline` и защита от утечки — обязательная основа; интерпретация результатов так же ценна, как и точность.

Направления развития. Настройка порога/баланса под `recall`, SHAP для более надёжной интерпретации, календарные признаки (сезонность, праздники) и онлайн-дообучение при дрейфе данных.

Приложение

Исходный код, обученная модель и инструкция: github.com/dorovskiikh/models.

Данные: Kaggle — Hotel Booking Demand (jessemostipak).