



Технологии искусственного интеллекта
и продвинутой аналитики

Прогнозирование отмены бронирований отеля

Доровских Софья Дмитриевна, Соловьева Амина
МБАВК251С

Санкт-Петербург, 2026



Бизнес-задача и её ML-формулировка

Что предсказываем: отменит ли гость бронь отеля (да / нет).

Зачем бизнесу: отмены в последний момент оставляют номер пустым и ведут к упущенной выручке; ранний прогноз помогает управлять овербукингом и депозитами.

Тип задачи: бинарная классификация.

Целевая метрика: F1-score. Классы несбалансированы (37% отмен), поэтому Accurasy не показательна, опираемся на F1.



Данные и разведочный анализ (EDA)

Источник: Kaggle, Hotel Booking Demand – 119 390 броней, 32 признака (табличные данные).

Признаки описывают:

- параметры брони: срок до заезда, длительность проживания, цена, депозит
- гостя: страна, состав гостей, повторный клиент
- канал бронирования: сегмент рынка, канал продаж, агент
- поведение: прошлые отмены, изменения брони, спецзапросы

Целевая переменная: is_canceled – 37% отмен / 63% заездов (умеренный дисбаланс).

Пропуски и выбросы: удалены колонка company (94% пустых) и битые строки (нулевые гости, отрицательная цена).

Ключевые показатели: депозит Non Refund отменяют почти в 100% случаев; городской отель чаще курортного (42% против 28%); чем больше срок до заезда, тем выше отмена.




Рис. 1. Доля отмен в зависимости от типа депозита и типа отеля.



Подготовка данных (Feature Engineering)

Пропуски: числовые — медиана; категориальные — категория Unknown; company удалена.

Кодирование категорий: One-Hot; редкие страны (из 177) объединены в общий бакет, чтобы не плодить колонки.

Масштабирование: StandardScaler — нужно логистической регрессии, деревьям не мешает.

Новые признаки и защита от утечки: флаг agent_known; удалены reservation_status и reservation_status_date, напрямую раскрывающие ответ.

Разбиение: train 80% / test 20% со стратификацией; предобработка обучается только на train.

Действие	Метод	Обоснование
Пропуски	числовые — медиана; категориальные — Unknown	медиана устойчива к выбросам; Unknown сохраняет строки
Кодирование	One-Hot; редкие страны → общий бакет	у country 177 значений — иначе сотни колонок
Масштабирование	StandardScaler (числовые)	нужно логрегу; деревьям не мешает
Новые признаки	флаг agent_known; удаление утечек	ID агента бесполезен как число; статус раскрывает ответ



Модели и метрики

Модель	F1 (тест)	Accuracy	Время обуч.
Baseline (всегда «не отменится»)	0.00	0.63	—
Logistic Regression	0.72	0.81	5 с
Decision Tree	0.77	0.84	3 с
Gradient Boosting	0.81	0.86	9 с
Random Forest	0.85	0.89	31 с

F1 — на отложенном тесте; качество подтверждено 5-fold кросс-валидацией. Лучшая модель — Random Forest.



Анализ результатов и интерпретация

Лучшая модель: Random Forest (F1 0.85, Accuracy 0.89). F1 на кросс-валидации и на тесте совпадают — переобучения нет.

Гипотеза EDA подтвердилась: связи нелинейные, поэтому ансамбли деревьев заметно обогнали логистическую регрессию.

Важность признаков: срок до заезда, цена за ночь, страна гостя, тип депозита, число спецзапросов.

Анализ ошибок: recall по отменам 0.81; самый дорогой промах – пропущенные отмены (упущенная выручка).




Рис. 2. Важность признаков (Random Forest): срок до заезда, цена, страна, тип депозита.



Жизненный цикл модели (MLOps)

Сохранение: весь pipeline (предобработка + модель) сохранён через joblib в `best_model.pkl` (со сжатием).

Инференс: на новых «сырых» данных прогноз работает сразу – предобработка зашита внутри pipeline.

Воспроизводимость: фиксированный `random_state`, данные тянутся через kagglehub, версии библиотек – в `requirements.txt`.

Дрифт данных: со временем поведение гостей меняется (сезоны, цены), поэтому нужен мониторинг качества и переобучение по расписанию.



Выводы и направления развития

Итог: построена рабочая модель, предсказывающая отмены с F1 0.85; ключевые драйверы понятны и объяснимы.

Можно ли внедрить: да – как скоринг риска брони для отдела бронирования.

Что улучшить: настройка порога под recall; SHAP для интерпретации; календарные признаки; онлайн-дообучение.

